

# NEX1

*Kajetán Poliak, Adam Novotný*

*24. října 2019*

## NEX - první domácí úkol

### 1. část

- Namerte data: experiment nastavte tak, aby byl znahodnenny !!!!! Poradi mereni si poznamenejte pro dalsi kontrolu pripadne zavislosti na poradi mereni. Jednotlive lidi ve skupine berte jako ruzne operatory experimentu (blokujte). Pocet replikaci u jednoho cloveka a jednoho casu vemte 1. V protokolu krom popisu experimentu diskutujte i jen promenne, ktere mohli mit na mereni vliv.

Experimentu se účastnili dva operátoři. Každý z operátorů se podrobil devíti měření (tečkování do 3 párů kruhů pomocí 3 technik dominantní, nedominantní a obou rukou), kde každé měření trvalo 10s. Celkově tedy máme 18 pozorování se čtyřmi vysvětlujícími proměnnými, operátor **Jmeno** na dvou úrovních, použití ruky **Ruka** na třech úrovních, velikost kruhu **Kruh** také na třech úrovních a pořadí **Poradi** pro oba operátory.

Pořadí měření bylo znáhodněno pomocí generátoru náhodné posloupnosti z [www.random.org](http://www.random.org). Jako první se vygenerovala náhodná posloupnost celých čísel od 1 do 9, která určovala pořadí měření. Následně se pomocí náhodné posloupnosti od 1 do 3 přiřadila jedna z úrovní proměnné **Ruka** ke každému ze tří papírů obsahujícímu tři různé velikosti kruhu.

Na měření mohlo mít vliv spousta faktorů. Mezi tyto faktory patří rozpoložení operátora, tedy různé polohy sedu při experimentu, psychický nátlak okolí nebo dlouhodobý fyzický a psychický stav operátora. Důvodem také mohlo být, že se experimentu každý z operátorů podrobil jiný den. Dalšími faktory mohly být nepřesnosti měření času druhým člověkem, různé psací potřeby operátorů nebo způsob držení papíru.

### 2. část

- Spoctete základní statistiky (mean, median a sd pro jednotlivé faktory - velikost, ruka, operator) Zobrazte namerena data (box plot, interaction plot, effects plot, ...) a okomentujte je co z danych obrazku muzeme pred samotnou analyzou rici o vysledku?

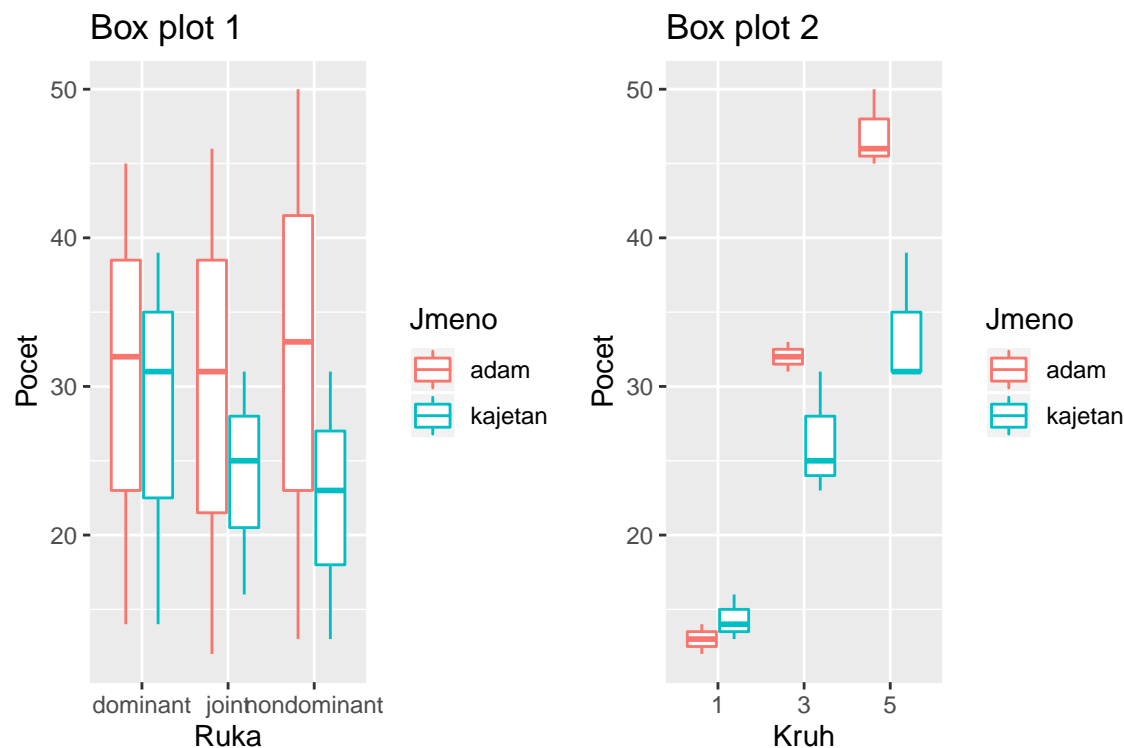
Zobrazme si nejprve základní statistiky, tedy postupně minimum, první kvartil, medián, třetí kvartil, maximum a směrovanou odchylku pro všechny úrovně.

##	adam	kajetan	dominant	nondominant	joint	1 cm
## Min.	12.00000	13.00000	14.00000	13.00000	12.00000	12.00000
## 1st Qu.	14.00000	16.00000	18.25000	15.50000	18.25000	13.00000
## Median	32.00000	25.00000	31.50000	27.00000	28.00000	13.50000
## Mean	30.66667	24.77778	29.16667	27.16667	26.83333	13.66667
## 3rd Qu.	45.00000	31.00000	37.25000	32.50000	31.00000	14.00000
## Max.	50.00000	39.00000	45.00000	50.00000	46.00000	16.00000
## Sd.	14.83240	9.038498	12.79714	14.06295	12.18879	1.36626
##	3 cm	5 cm				
## Min.	23.00000	31.00000				
## 1st Qu.	26.50000	33.00000				
## Median	31.00000	42.00000				
## Mean	29.16667	40.33333				
## 3rd Qu.	31.75000	45.75000				
## Max.	33.00000	50.00000				
## Sd.	4.119061	8.041559				


Tabulka zobrazuje základní statistiky experimentu. Vidíme, že operátoři mají průměr odlišný, kdy Adam má průměr větší. Oba mají podobná minima ale maximum Adama je o celých 11 vyšší. Stejně tak je vyšší střední hodnota počtu teček Adama. Maxima u proměnné **Ruka**, tedy dominant, nondominant a joint souvisí s operátorem Adam.

Podle očekávání vidíme, že hodnoty charakteristik proměnné **Kruh** jsou vyšší se zvětšujícím se poloměrem kruhu. Směrodatná odchylka u proměnných adam, kajetan, dominant, nondominant a joint dosahují poměrně vysokých hodnot. To je vysvětlitelné tím, že počet teček se pro každý kruh radikálně liší. Nejnižší průměrnou hodnotu z různých úrovní proměnné **Ruka** má joint.

Zobrazme si nyní postupně boxploty, interaction ploty a effects ploty.




Z boxplotu 1 vidíme, že Adam dosahoval ve všech úrovních **Ruka** větších průměrů, nejméně však u úrovně dominant. U úrovní nondominant a joint má Adam vyšší průměry i znatelně větší variance. V úrovních **Kruh** v boxplotu 2 dosahuje Kajetan většího průměru u nejmenšího kruhu, naopak Adam u ostatních dvou úrovních. Lze vidět, že na úrovních 3 cm a 5 cm má Adam větší počet teček i v rámci statistické odchylky.



Další boxploty nevypovídají, zdali je významný rozdíl mezi úrovněmi **Jmeno** a **Ruka**, naopak pozorujeme rozdíl mezi úrovněmi **Kruh**. V případě úrovně 1 cm pozorujeme i outlier, který však je dán malým počtem pozorování a zdánlivý velký rozdíl mezi hodnotami 16 a ostatními, jak můžeme vidět na hodnotách 1 cm.

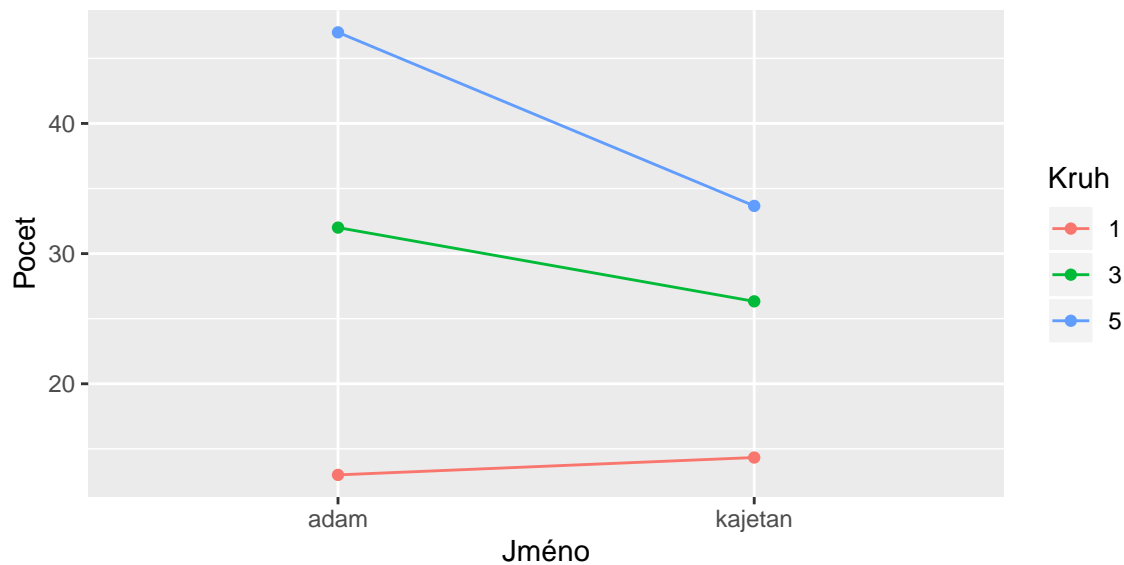
```
## [1] 12 13 14 14 13 16
```

V případě influence plotů v závislosti ruce na jménu pozorujeme, že ve všech úrovních má Adam větší v pořadí, průměrně maxima dosahuje u nondominant, dále dominant a joint. Kajetán maxima dosahuje u dominant, dále joint a nondominant. Interakce mezi proměnnými by mohla být významná.



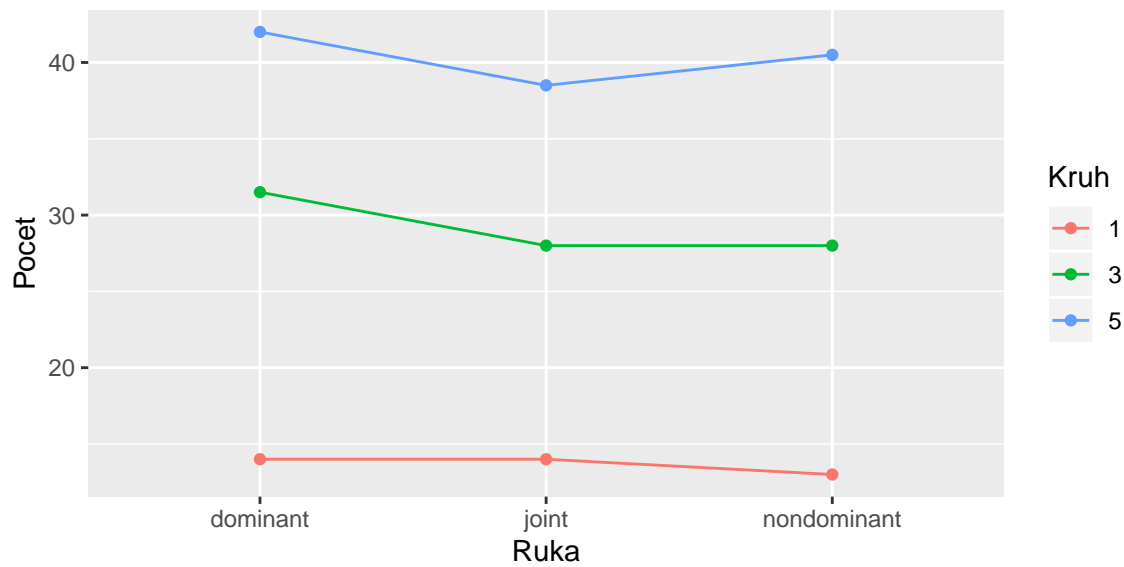
V případě závislosti kruhu na jménu pozorujeme, že v obou případech je největší počet pro 5 cm, dále 3 cm a 1 cm. Jak jsme již pozorovali dříve, Kajetán dosahuje většího počtu na úrovni 1 cm, jinak na všech úrovních Adam.

Influence plot – Kruh x Jméno




V případě závislosti kruhu na ruce nepozorujeme žádnou interakci.

Influence plot – Ruka x Kruh



V případě effect plotu pozorujeme již zmíněné okolnosti.





Před samotnou analýzou můžeme vidět, že úrovně proměnné **Kruh** by v analýze rozptylu a lineární regresi měly být signifikantní, u proměnných **Jmeno** a **Ruka** si nemůžeme být jistí. Můžeme však vidět, že rozptyly úrovní **Kruh** nebudou shodné, naopak u úrovní **Jmeno** a **Ruka** očekáváme stejné rozptyly. Střední hodnoty u úrovní **Kruh** taktéž nebudou shodné, ale stejně tak jako dříve u proměnných **Jmeno** a **Ruka** si nemůžeme být jistí.

### 3. část

- Zamerte se zvláště na faktory ruka a velikost kola. Otestujte hypotézu o shodnosti rozptylu pro jednotlivé úrovně a vhodným testem overte stejnost středních hodnot. Proveďte Tukey HSD a Fisher LSD test pro parové porovnání středních hodnot jednotlivých skupin s vybranou korekcí p-hodnoty.

Pro otestování shodnosti rozptylu a středních hodnot použijeme  $F$ -test, resp.  $t$ -test. U těchto testů předpokládáme normalitu dat. Nejprve si vykresleme histogramy a následně otestujeme hypotézu normality Shapirovým–Wilkovým testem. V celé práci uvažujeme  $\alpha = 0,05$ .

V případě proměnné **Jmeno** histogramy nenaznačují případné porušení normality, navíc testy nezamítáme normalitu. Můžeme tedy přejít k otestování shodnosti rozptylů.



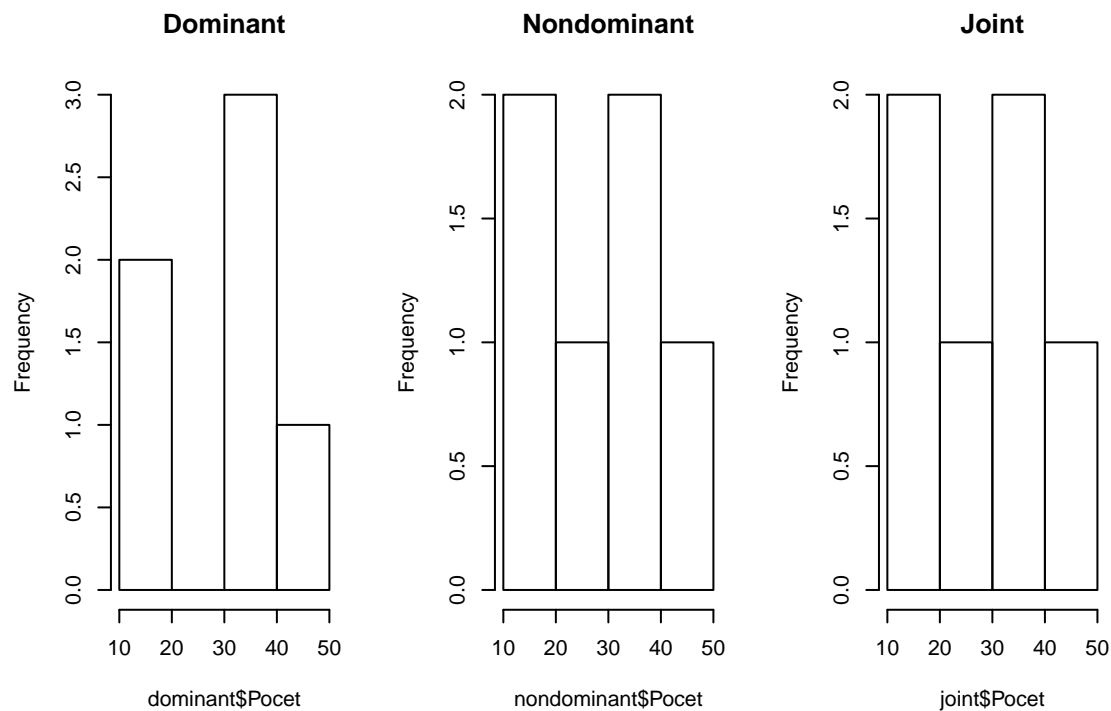
```
##
## Shapiro-Wilk normality test
##
## data: adam$Pocet
## W = 0.88219, p-value = 0.1656

##
## Shapiro-Wilk normality test
##
## data: kajetan$Pocet
## W = 0.92229, p-value = 0.4116

##
## F test to compare two variances
##
## data: adam$Pocet and kajetan$Pocet
## F = 2.693, num df = 8, denom df = 8, p-value = 0.1827
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
## 0.607445 11.938599
## sample estimates:
## ratio of variances
## 2.692962
```

*F*-test pro operátory vrací p-hodnotu 0.1827, nezamítáme tedy nulovou hypotézu o rovnosti rozptylů.

Přecházíme k faktoru Ruka.



```
##
## Shapiro-Wilk normality test
##
## data:  dominant$Pocet
## W = 0.89281, p-value = 0.3332

##
## Shapiro-Wilk normality test
##
## data:  nondominant$Pocet
## W = 0.91686, p-value = 0.4831


##
## Shapiro-Wilk normality test
##
## data:  joint$Pocet
## W = 0.9526, p-value = 0.7613

##
## F test to compare two variances
##
## data:  dominant$Pocet and nondominant$Pocet
## F = 0.82808, num df = 5, denom df = 5, p-value = 0.8411
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.1158741 5.9177775
## sample estimates:
## ratio of variances
##      0.8280802
##
```

```
## F test to compare two variances
##
## data:  dominant$Pocet and joint$Pocet
## F = 1.1023, num df = 5, denom df = 5, p-value = 0.9175
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.1542474 7.8775351
## sample estimates:
## ratio of variances
##      1.102311
##
## F test to compare two variances
##
## data:  nondominant$Pocet and joint$Pocet
## F = 1.3312, num df = 5, denom df = 5, p-value = 0.7613
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.1862711 9.5130095
## sample estimates:
## ratio of variances
##      1.331164
```

Pro všechny úrovně nezamítám dle Shapiro-Wilkova testu normalitu.  $F$ -test vrací pro páry dominant-nondominant, dominant-joint a nondominant-joint respektive  $p$ -hodnoty 0.84, 0.92 a 0.76 nezamítáme tedy rovnosti rozptylů. Můžeme dodat, že pokud by nám nešlo o jednotlivé dvě skupiny vůči sobě, mohli bychom použít párový test.

Jako poslední testujeme proměnnou Kruh.



```
##
```



```

## Shapiro-Wilk normality test
##
## data:  one_cm$Pocet
## W = 0.92664, p-value = 0.5544

##
## Shapiro-Wilk normality test
##
## data:  three_cm$Pocet
## W = 0.8307, p-value = 0.109

##
## Shapiro-Wilk normality test
##
## data:  five_cm$Pocet
## W = 0.88926, p-value = 0.3143

##
## F test to compare two variances
##
## data:  one_cm$Pocet and three_cm$Pocet
## F = 0.11002, num df = 5, denom df = 5, p-value = 0.0301
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.01539515 0.78624240
## sample estimates:
## ratio of variances
##      0.1100196

##
## F test to compare two variances
##
## data:  one_cm$Pocet and five_cm$Pocet
## F = 0.028866, num df = 5, denom df = 5, p-value = 0.00139
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.004039244 0.206287311
## sample estimates:
## ratio of variances
##      0.02886598

##
## F test to compare two variances
##
## data:  three_cm$Pocet and five_cm$Pocet
## F = 0.26237, num df = 5, denom df = 5, p-value = 0.1683
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.03671384 1.87500430
## sample estimates:
## ratio of variances
##      0.2623711

```

*P*-hodnoty S-W testu pro úrovně 1 cm, 3 cm a 5 cm jsou postupně 0.55, 0.11 a 0.31, ani pro jednu z úrovní nezamítáme normalitu. *F*-test vrací pro dvojice 1cm-3cm, 1cm-5cm a 3cm-5cm *p*-hodnoty 0.030, 0.001 a 0.168 respektive. Pro dvojice 1cm-3cm a 1cm-5cm zamítáme nulovou hypotézu o rovnosti rozptylů.

Můžeme tedy přejít k otestování středních hodnot postupně pro proměnné `Jmeno`, `Ruka` a `Kruh`. Jedinou podmínkou použití  $t$ -testu je normalita, která je již otestována. Pro proměnnou `Jmeno` použijeme  $t$ -test a pro proměnné `Ruka` a `Kruh` použijeme párový  $t$ -test s korekcí “hochberg”. Pro proměnné `Jmeno` a `Ruka` uvažujeme pro test stejné rozptyly v rámci úrovní, naopak pro proměnnou `Kruh` ne.

```
##
## Two Sample t-test
##
## data: adam$Pocet and kajetan$Pocet
## t = 1.0171, df = 16, p-value = 0.3242
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -6.384906 18.162684
## sample estimates:
## mean of x mean of y
## 30.66667 24.77778

##
## Pairwise comparisons using t tests with pooled SD
##
## data: dat$Pocet and dat$Ruka
##
##          dominant joint
## joint      0.97      -
## nondominant 0.97      0.97
##
## P value adjustment method: hochberg

##
## Pairwise comparisons using t tests with pooled SD
##
## data: dat$Pocet and dat$Kruh
##
##      1      3
## 3 0.00027 -
## 5 8.4e-07 0.00229
##
## P value adjustment method: hochberg
```

Pro proměnnou `Jmeno` nezamítáme hypotézu shodnosti středních hodnot, pro proměnnou `Ruka` taktéž nezamítáme mezi všemi úrovněmi, naopak u proměnné `Kruh` nulovou hypotézu shodnosti středních hodnot zamítáme.

Můžeme přejít k další podúloze v rámci této části, a to Tukey HSD a Fisher LSD test pro párové porovnání středních hodnot.

```
aov_celk = aov(Pocet ~ Jmeno + Ruka + Kruh, data = dat) #ruka neni stat. vyznamna
summary(aov_celk)
```

```
##          Df Sum Sq Mean Sq F value    Pr(>F)
## Jmeno      1  156.1    156.1    7.728 0.0167 *
## Ruka        2   19.1     9.6    0.473 0.6342
## Kruh        2 2152.1   1076.1   53.285 1.07e-06 ***
## Residuals  12  242.3     20.2
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
LSD1 <- LSD.test(aov_celk, "Jmeno"); LSD1$groups
```

```
##          Pocet groups
## adam      30.66667      a
## kajetan 24.77778      b
```

```
LSD2 <- LSD.test(aov_celk, "Ruka"); LSD2$groups
```

```
##          Pocet groups
## dominant 29.16667      a
## nondominant 27.16667      a
## joint    26.83333      a
```

```
LSD3 <- LSD.test(aov_celk, "Kruh"); LSD3$groups
```

```
##          Pocet groups
## 5 40.33333      a
## 3 29.16667      b
## 1 13.66667      c
```

Fisherův LSD test radí spojit všechny úrovně v rámci proměnné Ruka, tedy tuto proměnnou v analýze nepoužít. Naopak pro proměnné Jmeno a Kruh radí žádné úrovně nespojovat. Navíc ANOVA pro faktor Ruka signifikantní není, proto jej vyhodíme z modelu.

Pokračujeme s Tukeyho HSD testem.

```
TukeyHSD(aov_celk, "Jmeno", ordered = FALSE, conf.level = alpha)
```

```
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Pocet ~ Jmeno + Ruka + Kruh, data = dat)
##
## $Jmeno
##          diff      lwr      upr      p adj
## kajetan-adam -5.888889 -10.5045 -1.273273 0.0166546
```

```
TukeyHSD(aov_celk, "Ruka", ordered = FALSE, conf.level = alpha)
```

```
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Pocet ~ Jmeno + Ruka + Kruh, data = dat)
##
## $Ruka
##          diff      lwr      upr      p adj
## joint-dominant -2.333333 -9.255132 4.588465 0.6509234
## nondominant-dominant -2.000000 -8.921799 4.921799 0.7272003
## nondominant-joint 0.333333 -6.588465 7.255132 0.9909481
```


```
TukeyHSD(aov_celk, "Kruh", ordered = FALSE, conf.level = alpha)
```

```
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Pocet ~ Jmeno + Ruka + Kruh, data = dat)
##
## $Kruh
```


```
##          diff      lwr      upr      p adj
## 3-1 15.50000  8.578201 22.42180 0.0001769
## 5-1 26.66667 19.744868 33.58847 0.0000007
## 5-3 11.16667  4.244868 18.08847 0.0027206
```

Tukeyho HSD test vrací pro proměnnou **Jmeno**  $p$ -hodnotu rovnou 0.017, nezamítáme tedy hypotézu, že úrovně mají různou střední hodnotu. Tento test na proměnnou **Ruka** vrací  $p$ -hodnoty indikující, že všechny úrovně patří do stejné skupiny. Výsledek je tedy shodný s předchozími LSD testy.

Výsledky LSD a HSD testů můžeme přehledně vykreslit. Vrchní tři zobrazují výsledky LSD testu a příslušnost do jednotlivých skupin, spodní tři testy pak HSD test, kdy pokud interval prochází nulou, tak je vhodné úrovně spojit.



#### 95% family-wise confidence intervals



#### 4.část

- Analyzujte data pomocí ANOVA (všechny proměnné berete jako faktor) - s předpokladem, že každý z účastníků experimentu tvoří jeden blok. - diskutujte výsledky, overte předpoklady, vykreslete QQ-plot, residua x fitted values, residua x čas, ... - diskutujte vliv znahodnění experimentu a vývoj reziduí v case (číslo měření)

Ve třetí části jsme z analýzy rozptylu vyřadili proměnnou **Ruka**, která nebyla statisticky významná. V této části nejprve zkusíme model, který bude obsahovat proměnné **Jmeno**, **Ruka**, jejich interakci a **Poradi**.

```
##          Df Sum Sq Mean Sq F value    Pr(>F)
## Jmeno      1  156.1   156.1    24.546 0.000433 ***
## Kruh       2 2152.1  1076.1   169.252 5.48e-09 ***
## Poradi     1   22.9    22.9     3.601 0.084297 .
## Jmeno:Kruh  2  168.6    84.3    13.261 0.001173 **
## Residuals 11   69.9     6.4
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

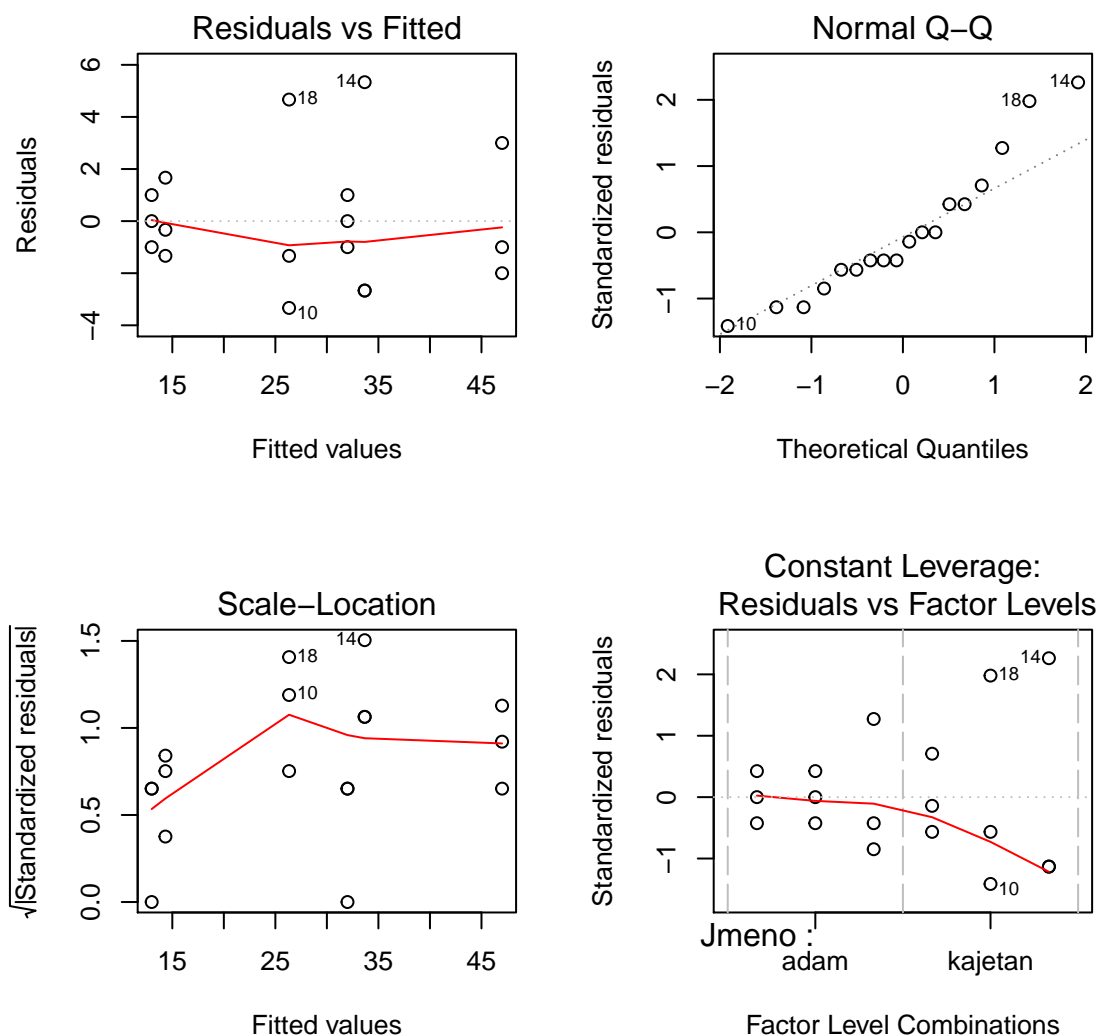
Ukazuje se, že všechny zmíněné proměnné jsou významné na hladině významnosti  $\alpha = 0.05$  až na proměnnou Poradi, jejíž  $p$ -hodnota avšak není tak vysoká. V dalším modelu ji ale uvažovat nebudeme.

```
##           Df Sum Sq Mean Sq F value    Pr(>F)
## Jmeno      1  156.1    156.1   18.727 0.000983 ***
## Kruh       2 2152.1   1076.1  129.127 7.66e-09 ***
## Jmeno:Kruh  2  161.4     80.7    9.687 0.003131 **
## Residuals 12  100.0      8.3
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Ověříme podmínky analýzy rozptylu, tedy normalita dat pomocí Shapirova–Wilkova testu a Lillieforsova testu na rezidua, navíc homoskedasticitu otestujeme Breuschovým–Paganovým testem a Levenovým testem.

```
##
## Shapiro-Wilk normality test
##
## data:  aov1$residuals
## W = 0.92219, p-value = 0.1413
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  aov1$residuals
## D = 0.16667, p-value = 0.2062
##
## studentized Breusch-Pagan test
##
## data:  aov1
## BP = 8.8802, df = 5, p-value = 0.1139
## Levene's Test for Homogeneity of Variance (center = median)
##           Df F value Pr(>F)
## group    5  0.4291 0.8199
##          12
```

Vykresleme si ještě postupně rezidua vůči fitted values, Q-Q plot pro grafickou vizualizaci normality; scale location plot pro homoskedasticitu a rezidua vůči proměnné **Jmeno**.



Grafy mají rezidua víceméně rovnoměrně rozdělené a body zaujímají horizontální polohu. Jako outlier by být označen bod 14. V případě všech testů zamítáme a navíc graficky jsme ověřili, že podmínky analýzy rozptylu jsou splněny.

Diskutujeme významnost proměnné **Poradi**. Vypišme si rezidua, zda se jejich hodnota nemění v čase. Jak můžeme vidět, tak ne razantně (výjimkou může být bod 14, což potvrzuje předchozí analýzu). To potvrzuje statistická nevýznamnost proměnné **Poradi**.

```
##      1      2      3      4      5      6
## 1.3983740 -0.1260163 -0.6016260 -0.1260163 -0.6504065 -0.1747967
##      7      8      9     10     11     12
## 0.3008130 -1.2723577 1.2520325 -1.5853659 1.2398374 -0.6341463
##     13     14     15     16     17     18
## -1.7926829 5.6829268 -1.8577236 0.6178862 -3.8902439 2.2195122
```

Za finální ANOVA model jsme na základě signifikance proměnných vybrali model  $\text{Pocet} \sim \text{Jmeno} * \text{Kruh}$ . Tento model splňuje podmínky ANOVA. Konkrétně, na základě  $p$ -hodnoty testů normality nezamítáme normalitu reziduí a stejně tak na základě testů homoskedasticity nezamítáme homoskedasticitu.

## 5. část

- Porovnejte a diskutujte výsledky z bodu 3 a 4.

Ve třetím bodu jsme několika testy (Fisher LSD, Tukey HSD) určili, že faktory **Ruka** a **Jmeno** mají úroveň pocházející z různých skupin. Jinak to bylo s faktorem **Kruh**, kde všechny úrovně patří do stejné. Pairwise *t*-test u faktoru **Jmeno** zamítá shodnost středních hodnot, u faktoru **Kruh** nikoliv. Model ANOVA má u faktorů **Jmeno** a **Kruh** *p*-hodnoty  $< 0.05$ , je zde signifikantní vliv na **Pocet**. Závěry LSD, HSD testů a ANOVA si tedy odpovídají.

## 6. část

- Pokud data nesplňují předpoklady pro použití ANOVA, diskutujte možné transformace (logaritmická, Box-Cox, ...) a důvod, proč data předpoklady nesplňují? Vyskyt outlieru, způsob měření, divný operator, ...

Data splňují předpoklady, tudíž nebudeme používat jakoukoli transformaci. V průběhu analýzy jsme identifikovali nějaké outliery, které ale neměly vliv na model.

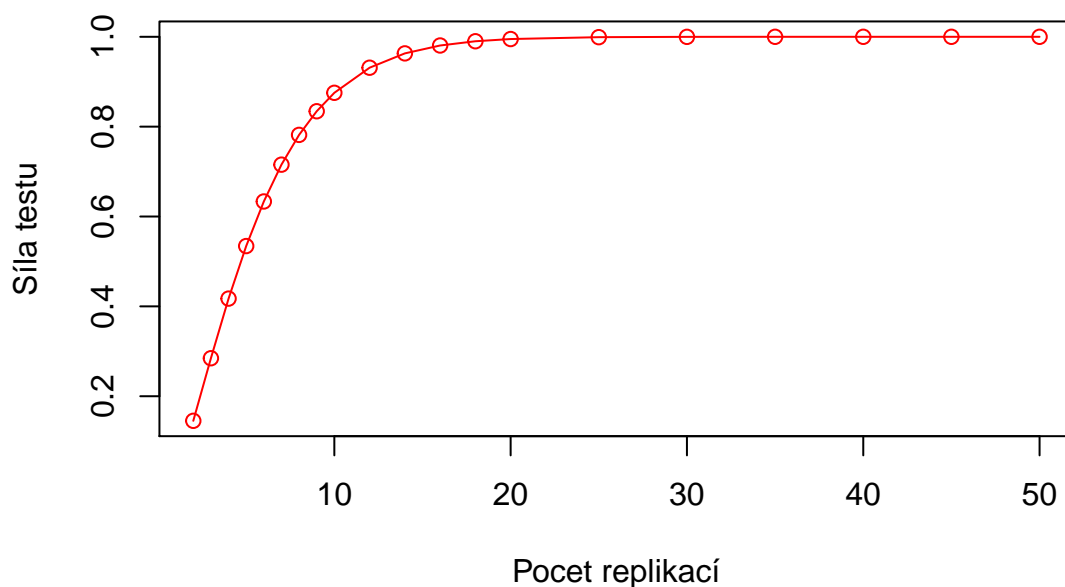
## 7. část

- Vyberte nejvhodnější model a i kdyby nesplňoval předpoklady pro použití ANOVA reste následující:
  - Spočítejte sílu testu v ANOVA (pro max. dvoufaktorovou analýzu - jeden z faktorů zanedbejte, nebo vezmete měření pro jednu jeho konkrétní úroveň)
  - Předpokládejme, že standardní odchylka disturbance bude pro provedení experimentu 4 a maximální (pro nás signifikantní) rozdíl, který chceme detekovat je 5 bodů v kruhu. Spočítejte počet potřebných replikací, aby síla výsledného testu byla větší než 0.9

```
##
##      Balanced one-way analysis of variance power calculation
##
##      groups = 2
##      n = 9
##      between.var = 17.33951
##      within.var = 16
##      sig.level = 0.05
##      power = 0.8342625
##
## NOTE: n is number in each group

##
##      Balanced one-way analysis of variance power calculation
##
##      groups = 2
##      n = 10.75368
##      between.var = 17.33951
##      within.var = 16
##      sig.level = 0.05
##      power = 0.9
##
## NOTE: n is number in each group
```

## Síla testu v závislosti na počtu replikací



Pro výpočet síly testu bereme 5% hladinu významnosti. Předpokládáme, že statistická odchylka disturbancí pro experiment je 4 (rozptyl = 16). Síla testu pro dvouúrovňový faktor *Jmeno*, kde máme 9 pozorování, je 0.834. Pro sílu testu větší než 0.9 bychom potřebovali alespoň 11 replikací. Tato skutečnost je viditelná i z grafu závislosti síly testu na počtu replikací.

## 8. část

- Vytvorte regresni model, kde nebudete uvažovat bloky a velikost kruhu bude kvantitativni promenna. - zkuste pridať do modelu i druhou mocninu a porovnejte dva regresni modely mezi sebou a vyberte vhodnejši - overte predpoklady pro pouziti vybraného modelu a vykreslete QQ-plot, residua x fitted values, residua x prumer , ...

Sestrojíme lineární regresní model, kde neuvažujeme bloky, jedinou významnou proměnnou je tedy proměnná *Kruh*, která je kvantitativní.

```
##
## Call:
## lm(formula = Pocet ~ Kruh, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -10.0556  -2.3056  -0.3889   3.7778   8.9444
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    1.056      3.256   0.324    0.75
## Kruh           13.333      1.507   8.845 1.47e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```



```
## Residual standard error: 5.222 on 16 degrees of freedom
## Multiple R-squared:  0.8302, Adjusted R-squared:  0.8196
## F-statistic: 78.24 on 1 and 16 DF,  p-value: 1.472e-07
```

V lineárním regresním modelu  $\text{Pocet} \sim \text{Kruh}$ , dostáváme  $R_{adj}^2 = 82$  a proměnnou kruh jako signifikantní na 1% hladině významnosti.

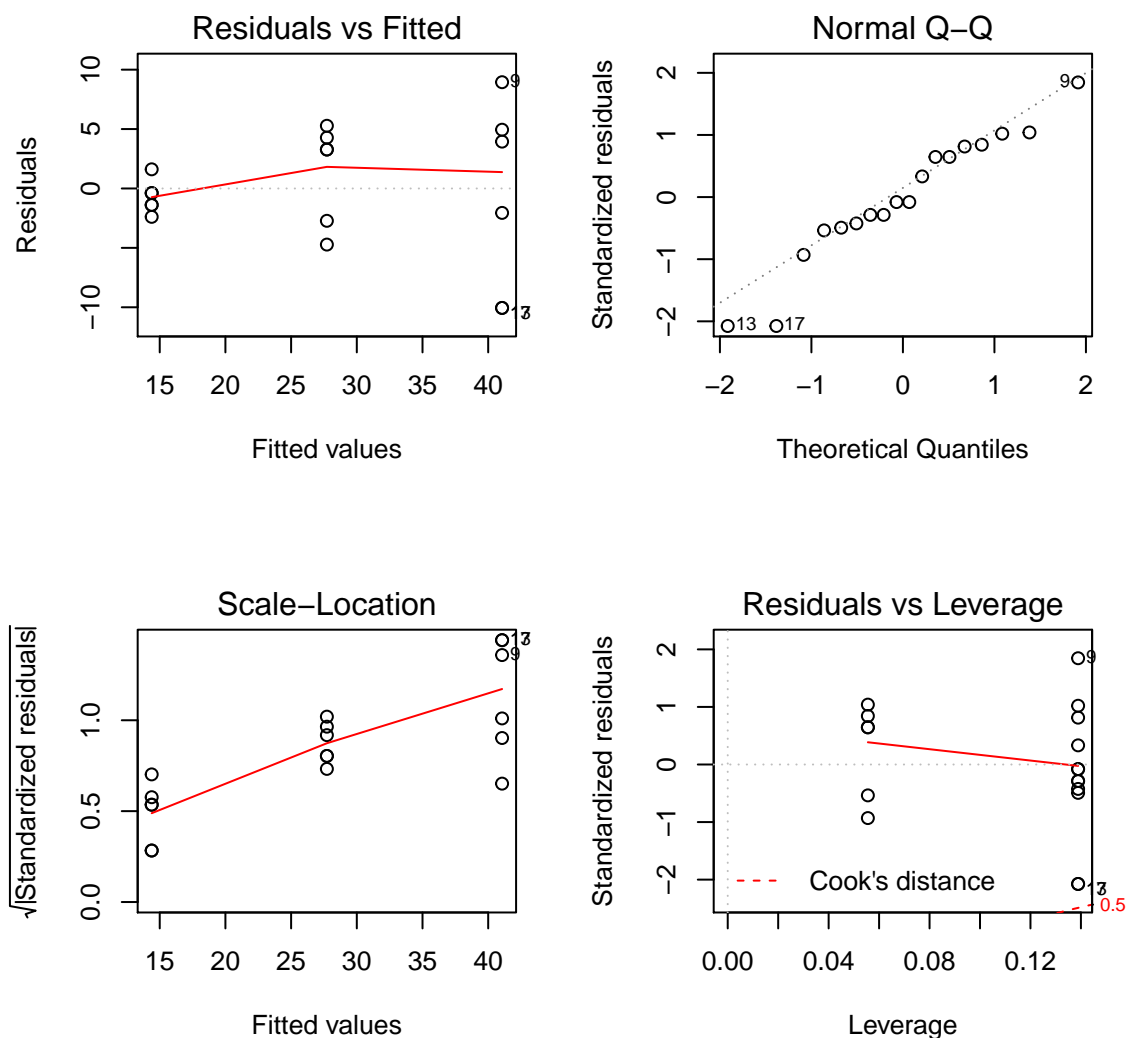
Zkusme model s kvadratickou proměnnou.

```
##
## Call:
## lm(formula = Pocet ~ Kruh + I(Kruh^2), data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -9.3333 -1.5833  0.3333  2.7083  9.6667
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -6.167      9.388  -0.657  0.5212
## Kruh           22.000     10.661   2.064  0.0568 .
## I(Kruh^2)     -2.167      2.638  -0.821  0.4243
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.276 on 15 degrees of freedom
## Multiple R-squared:  0.8375, Adjusted R-squared:  0.8159
## F-statistic: 38.66 on 2 and 15 DF,  p-value: 1.205e-06
```

Pokud do modelu přidáme i druhou mocninu, získáváme nesignifikantní proměnné a  $R^2$  se mírně snížil. Tento model dále neuvažujeme.

Ověřme nyní podmínky modelu jak testováním, tak graficky.

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  residuals(linmod)
## D = 0.13008, p-value = 0.5816
##
##  Shapiro-Wilk normality test
##
## data:  resid(linmod)
## W = 0.94847, p-value = 0.4015
##
##  studentized Breusch-Pagan test
##
## data:  linmod
## BP = 7.7543, df = 1, p-value = 0.005358
```



Lillieforsův test ani Shapiro-Wilkův test nezamítají hypotézu normality reziduí. Breusch-Paganův test zamítá homoskedasticitu. Problém heteroskedasticity je však zřetelný i z grafu Scale-Location.

Z důvodu výskytu heteroskedasticity použijeme logaritmickou transformaci prvního z modelů.

```
##
## Call:
## lm(formula = log(Pocet) ~ Kruh, data = dat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.31873 -0.11145 -0.02209  0.14167  0.27823
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   2.14938    0.11703  18.366 3.54e-12 ***
## Kruh           0.53445    0.05417   9.865 3.32e-08 ***
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1877 on 16 degrees of freedom
## Multiple R-squared:  0.8588, Adjusted R-squared:  0.85
## F-statistic: 97.33 on 1 and 16 DF,  p-value: 3.315e-08
```

Jak Intercept, tak Kruh jsou signifikantní, hodnota  $R^2 = 85$  je postačující. Nezamítáme jak normalitu reziduí, tak homoskedasticitu. Vidíme zlepšení na Scale-Location grafu. Máme tedy finální model.

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  residuals(linmod_log)
## D = 0.10418, p-value = 0.8718

##
##  Shapiro-Wilk normality test
##
## data:  resid(linmod_log)
## W = 0.95586, p-value = 0.5242

##
##  studentized Breusch-Pagan test
##
## data:  linmod_log
## BP = 2.0629, df = 1, p-value = 0.1509
```

